Wykorzystanie bazy dokumentowej MongoDB

Zbiór danych

https://www.kaggle.com/datasets/davidcariboo/player-scores

Zbiór danych dotyczący meczy piłkarskich. Każdy mecz ma wiele zdarzeń, co pozwala na zagnieżdżenie. Zdarzenia mają sporo cech. Zbiór jest dosyć spory (miliony rekordów).

Instalacja

Baza została zainstalowana w AWS, korzystając z rozwiązania Atlas od MongoDB.

Upload danych do bazy

Napisałem program w Python, który umieszcza dane w bazie:

```
import os

import kagglehub
import pandas as pd
from pymongo import MongoClient
from tqdm import tqdm

path = kagglehub.dataset_download("davidcariboo/player-scores")

clubs = pd.read_csv(os.path.join(path, "clubs.csv"))
game_events = pd.read_csv(os.path.join(path, "game_events.csv"))
game_lineups = pd.read_csv(os.path.join(path, "game_lineups.csv"))
games = pd.read_csv(os.path.join(path, "games.csv"))
player_valuations = pd.read_csv(os.path.join(path, "player_valuations.csv"))
players = pd.read_csv(os.path.join(path, "players.csv"))


client = MongoClient(os.getenv("MONGO_CONN_STR")
assert client.server_info()["ok"] == 1

db = client["football_data"]
db.list_collection_names()

clubs_collection = db["clubs"]
clubs_collection.insert_many(clubs.to_dict(orient="records"))

players_collection = db["players"]
players["valuations"] = (
```

```
    player_valuations.groupby("player_id")
    .apply(lambda x: x.to_dict(orient="records"))
    .to_dict()
)
players_collection.insert_many(players.to_dict(orient="records"))


for game in tqdm(games.iterrows(), total=games.shape[0]):
    game_row = game[1]
    lineup = game_lineups[game_lineups["game_id"] == game_row["game_id"]]
    events = game_events[game_events["game_id"] == game_row["game_id"]]
    game_dict = game_row.to_dict()
    game_dict["lineup"] = lineup.to_dict(orient="records")
    game_dict["events"] = events.to_dict(orient="records")
    db["games"].insert_one(game_dict)
```

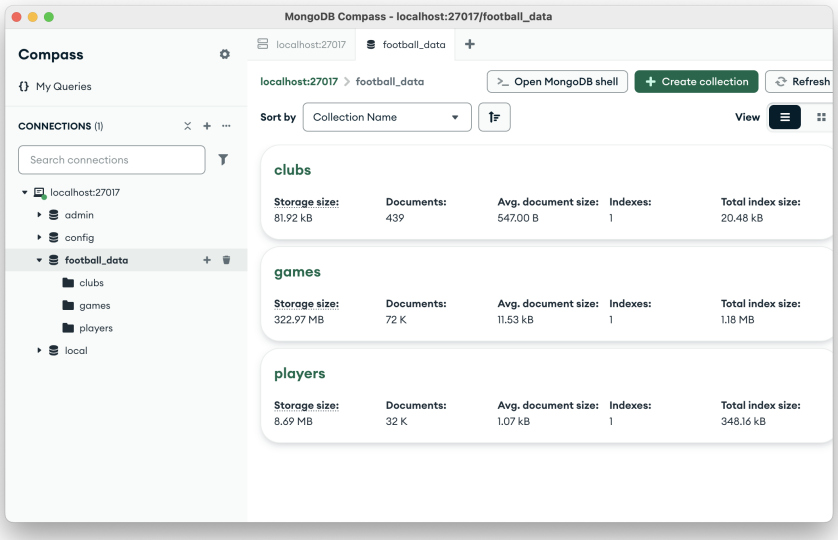

Dane zostały zagnieżdżone w następujący sposób:

```
|
|-- players
|   |-- valuations
|
|-- clubs
|
|-- games
    |- events
    |- lineups
```

Zagnieżdżenie `events` i `lineups` w grach ma sens, ponieważ są one nierozłącznie powiązane z grami. `players` nie zostało zagnieżdżone w `clubs` ponieważ gracze mogą zmieniać kluby. `valuations` zostało zagnieżdżone w `players`, ponieważ wycena jest związana nierozłącznie z zawodnikiem.

Zagnieżdżone dane

Przykład zagnieżdżenia `lineup` w `game`:

Referencja

Poniższe zapytanie liczy sumę wartości wszystkich zawodników grających w danym meczu.

```
{
        "$lookup": {
            "from": "players",
```

```
            "localField": "lineup.player_id",
            "foreignField": "player_id",
            "pipeline": [
                {"$project": {"market_value_in_eur": 1, "_id": 0}}
            ],
            "as": "player"
        }
    },
    {
        "$set": {
            "total_market_value": {
                "$sum": {
                    "$map": {
                        "input": "$player",
                        "as": "p",
                        "in": "$$p.market_value_in_eur"
                    }
                }
            }
        }
    },
    {
        "$limit": 100
}
```

```
    {'market_value_in_eur': 22000000.0},
    {'market_value_in_eur': 30000000.0}],
 'total_market_value': 139375000.0}
```

Analiza wydajności indeksów

Będę wykonywał poniższą kwerendę i sprawdzał jak na jej czas wykonania wpływa zakładanie indeksów.

```
{
  $expr: { $gte: [{ $add: ["$home_club_goals", "$away_club_goals"] }, 6] }
}
```

Bez indeksów

Z indeksem na `away_club_goals`

Z indeksami na `away_club_goals` i `home_club_goals`

Autoinkrementacja

Zaimplementowana za pomocą funkcji

```
> db.createCollection("counters");
< { ok: 1 }
> db.counters.insertOne({
  _id: "player_id",
  sequence_value: 2000000
  })
< {
    acknowledged: true,
    insertedId: 'player_id'
  }
> function getNextSequenceValue(sequenceName) {
      const sequenceDocument = db.counters.findOneAndUpdate(
          { _id: sequenceName },
          { $inc: { sequence_value: 1 } },
          { returnDocument: "after" }
      )
      return sequenceDocument.sequence_value
  }
< [Function: getNextSequenceValue]
> echo $?
✖ ▸ SyntaxError: Missing semicolon. (1:4)

    > 1 | echo $?
        |     ^
> ;
> db.players.insertOne({
      player_id: getNextSequenceValue("player_id"),
      name: "Tomasz Mycielski"
  })
< {
    acknowledged: true,
    insertedId: ObjectId('6755c66d783872f391e35ac8')
  }
> db.players.find().sort({ player_id: -1 }).limit(1)
< {
    _id: ObjectId('6755c66d783872f391e35ac8'),
    player_id: 2000001,
    name: 'Tomasz Mycielski'
  }
football_data>
```

MapReduce

Próbowałem wykorzystać `mapReduce`, ale otrzymałem komunikat:

`DeprecationWarning: Collection.mapReduce() is deprecated. Use an aggregation instead.`

Wykorzystałem zatem agregację do policzenia ile goli zostało strzelonych:

```
> db.games.aggregate([
    {
      $project: {
        total_goals: {
          $add: ["$home_club_goals", "$away_club_goals"]
        }
      }
    },
    {
      $group: {
        _id: null,
        total_goals_sum: {
          $sum: "$total_goals"
        }
      }
    },
    {
      $project: {
        _id: 0,
        total_goals_sum: 1
      }
    }
  ]);
< {
    total_goals_sum: 89242
  }
```

Autoinkrementacja

Stworzyłem trigger w bazie, który wywołuje poniższą funkcję.

```
exports = async function(changeEvent) {
    var docId = changeEvent.fullDocument._id;

    const countercollection = context.services.get("Cluster0").db(changeEvent.ns.db).collect
    const playerscollection = context.services.get("Cluster0").db(changeEvent.ns.db).collect

    var counter = await countercollection.findOneAndUpdate({_id: changeEvent.ns },{ $inc: {
    var updateRes = await playerscollection.updateOne({_id : docId},{ $set : {autoincrement(

    console.log(`Updated ${JSON.stringify(changeEvent.ns)} with counter ${counter.seq_value}
    };
```

Prezentacja działania

Najpierw dodaję trzech nowych graczy:

```
db.players.insertOne({
"name": "Aaa Aaa"
})
{
  acknowledged: true,
  insertedId: ObjectId('6755ffb2813e471ef56767fa'
}
db.players.insertOne({
"name": "Bbb Bbb"
})
{
  acknowledged: true,
  insertedId: ObjectId('6755ffb8813e471ef56767fb'
}
db.players.insertOne({
"name": "Ccc Ccc"
})
{
  acknowledged: true,
  insertedId: ObjectId('6755ffbe813e471ef56767fc'
}
```

Potem sprawdzam ich liczniki:

```
db.players.find({ autoincrementCounter: { $exists: true } });
{
  _id: ObjectId('6755ffb2813e471ef56767fa'),
  name: 'Aaa Aaa',
  autoincrementCounter: 2
}
{
  _id: ObjectId('6755ffb8813e471ef56767fb'),
  name: 'Bbb Bbb',
  autoincrementCounter: 3
}
{
  _id: ObjectId('6755ffbe813e471ef56767fc'),
  name: 'Ccc Ccc',
  autoincrementCounter: 4
}
```